

빅데이터 처리를 위한 분산처리시스템

강사: 신 인 호 교수

목 차

1. 리눅스 [linux]명령어
 - 1.1) 명령어입문
 - 1.2) 디렉토리와 파일
 - 1.3) 리눅스 에디터
 - 1.4) 파일접근권한 설정
 - 1.5) 관리자권한 실행
 - 1.6) Shell Program 작성

목 차

1. 데이터

1.1 데이터와 정보

1.2 데이터의 유형

1.3 데이터의 종류

1.4 데이터 샘플

2. 빅데이터 처리방식

2.1 빅데이터 처리방식의 종류

2.2 배치처리

2.3 대화형처리

2.4 실시간처리

3. 아파치 하둡(Apache Hadoop)

3.1 File System

3.2 Storage System

3.3 하둡 소개

3.4 하둡 구성

목 차

- 35 하둡 분산 파일시스템
- 36 하둡 분산 처리시스템
- 35 고가용성(HA) HDFS
- 4. 빅데이터 하둡에코 솔루션
 - 4.1 클라우데라
 - 4.2 호튼웍스
- 5. 빅데이터 클라우드 컴퓨팅
 - 5.1 MS Azure
 - 5.2 아마존 AWS
 - 5.3 구글 GCP
- 6. 빅데이터 실습
 - 6.1) WordCount 실습
 - 6.2) Azure 하둡구축
 - 6.3) RasPberry를 활용한 하둡설치 및 운영

1. 데이터


1.1 데이터와 정보

1.2 데이터의 유형

1.3 데이터의 종류

1.4 데이터 샘플

1.1 데이터와 정보



데이터

- 분석을 위한 정보를 추출하는 데 사용되는 원본
- 분석되지 않은, 조직화되지 않은, 관련이 없는 중단 없는 자료
- 의미없는 실체이므로 아무 것도 해석하지 않으며

정보

- 자료를 지각 할 수 있습니다.
- 데이터에 의미를 부여하는 특별한 방식으로 해석된다
- 자료간에 의미가 있고 관련성이 있습니다

시사기획. 빅데이터 세상을 바꾼다.

1.1 데이터와 정보

1.1 데이터 VS 정보

비교기준	데이터	정 보
의미	데이터는 정제되지 않은 사실 및 수치이며 컴퓨터 시스템의 입력으로 사용됩니다.	정보는 처리 된 데이터의 출력입니다.
형질	데이터는 원자재를 포함하고 어떤 의미도 가지지 않는 개별 단위입니다.	정보는 집합 적으로 논리적인 의미를 지닌 제품 및 데이터 그룹입니다.
의존	그것은 정보에 의존하지 않습니다..	그것은 데이터에 의존합니다.
특질	막연한	특유한.
측정단위	비트 및 바이트 단위로 측정됩니다.	시간, 수량 등 의미있는 단위로 측정

1.2 데이터의 유형

원천자료에 따라

+ 원천자료의 종류

거래자료 (Transaction Data)	물품이나 서비스의 매매로 발생하는 데이터
추적장치자료 (Tracking Device Data)	사람이나 물체의 위치, 이동을 추적하여 발생하는 데이터
센서자료 (Sensor Data)	다양한 센서를 통해 수집할 수 있는 데이터
온라인 활동자료 (Online Behavior Data)	온라인 상의 활동에 의해 발생하는 데이터
의견자료 (Opinion Data)	뉴스나 개인적 SNS활동 등에 의해 발생하는 데이터
행정자료 (Administrative Data)	공공기관에서 조사하여 만들어진 데이터

1.2 데이터의 유형

분류기준에 따라

+ 데이터의 분류기준


생성 주체에 따른 분류	데이터 유형에 따른 분류	데이터 수집방식에 따른 분류
■ 기계 데이터 ■ 사람 데이터 ■ 관계 데이터	■ 정형 데이터 ■ 반정형 데이터 ■ 비정형 데이터	■ 내부 데이터 ■ 외부 데이터

+ 데이터의 분류에 따른 데이터 종류

분류 기준	빅데이터 유형	종류
생성 주체	기계 데이터	애플리케이션, 센서 등을 통해 수집되는 데이터 : 애플리케이션 서버 로그 데이터, 센서 데이터, 위치 데이터 등
	사람 데이터	불특정 다수로부터 생성되는 데이터 : 트위터, 블로그, 이메일, 게시판 등
	관계 데이터	사람 간 또는 개체 간의 관계를 표현하는 데이터 : 트위터, 페이스북, 링크드인 등
데이터 유형	정형 데이터	고정된 필드에 저장된 데이터 : 데이터베이스, 스프레드 시트 등
	반정형 데이터	고정된 필드에 저장되어 있지는 않지만 메타데이터나 스키마를 포함하는 데이터 : XML, HTML, JSON 등
	비정형 데이터	고정된 필드에 저장되어 있지 않은 데이터 : 텍스트 문서, 이미지/동영상 등
데이터 수집방식	내부 데이터	자체적으로 보유한 내부 파일시스템이나 데이터베이스 관리시스템 등에 접근하여 데이터를 수집
	외부 데이터	웹 크롤링 엔진을 통해 인터넷 링크의 모든 페이지 복사본을 생성함으로써 데이터를 수집

1.3 데이터의 종류

1) 빅데이터 분석을 위한 데이터



+ 정형 데이터(Structured Data)

- 정형 데이터의 형태
 - 관계형 데이터베이스 시스템의 테이블과 같이 고정된 칼럼(Column)에 저장되는 데이터와 파일
 - 지정된 로우(Row, 행)와 칼럼(Column, 열)에 의해 데이터의 속성이 구별되는 스프레드시트 형태의 데이터
- 관계형 데이터베이스 시스템의 정형 데이터를 비정형 데이터(Unstructured Data)와 비교할 때 가장 큰 차이점은 **데이터의 스키마 지원여부**임

스키마에 의해 정의된 데이터

Column1	Column2	Column3	Column4
Data	Data	Data	Data
Data	Data	Data	Data
Data	Data	Data	Data
Data	Data	Data	Data

칼럼에 의해 정의된
데이터

정형데이터 구조

1.3 데이터의 종류

+ 반정형 데이터(Semi-structured Data)

■ 정형 데이터와 반정형 데이터 형태의 비교



```
[{"Sepal.Length":5.1,"Sepal.Width":3.5,"Petal.Length":1.4,"Petal.Width":0.2,"Species":"setosa"}, {"Sepal.Length":4.9,"Sepal.Width":3,"Petal.Length":1.4,"Petal.Width":0.2,"Species":"setosa"}, {"Sepal.Length":4.7,"Sepal.Width":3.2,"Petal.Length":1.3,"Petal.Width":0.2,"Species":"setosa"}, {"Sepal.Length":4.6,"Sepal.Width":3.1,"Petal.Length":1.5,"Petal.Width":0.2,"Species":"setosa"}]
```

일반적인 반정형 데이터의 형태


+ 비정형 데이터(Unstructured Data)

- 데이터 세트가 아닌 **하나의 데이터가 수집 데이터로 객체화**되어 있음
- 대표적인 비정형 데이터
 - 언어 분석이 가능한 텍스트 데이터
 - 이미지, 동영상 등의 멀티미디어 데이터
- 비정형 데이터의 특징
 - 웹에 존재하는 데이터의 경우 HTML 형태로 존재하여 반정형 데이터로 구분할 수도 있음
 - 특정한 경우 텍스트 마이닝을 통해 데이터를 수집하는 경우도 존재하므로 명확한 구분은 어려움

1.3 데이터의 종류

2) 수집위치에 따른 데이터

- + 데이터의 수집위치는 **원천 시스템과 연계를 위한 인터페이스의 기술적 방법 및 정책의 차이** 때문에 중요함



+ 내부 데이터

- 물리적 저장소의 위치가 내부에 있는 데이터
- 데이터 제공자와 상호 협약에 의한 의사소통이 가능함
- 기술적 제약도 적은 편이라서 수집, 분석에 용이함

+ 외부 데이터

- 원천 데이터의 저장소가 외부 시스템에 있는 데이터
- 데이터 제공자와 협약된 관계가 아니면 의사소통이 불가능함
- 수집을 위한 주기 및 방법에 관한 분석이 필요함
- 데이터의 전처리 과정 없이 가능하다면 원본 데이터를 수집 후, 수집 시스템에서 처리할 수 있도록 인터페이스를 설계하는 것이 바람직함

1.4 데이터 샘플

1.10 데이터 샘플

1 반정형 Data: HTML

- ☞ HyperText Markup Language의 약자
- ☞ 웹 페이지를 만들 때 사용되는 문서 형식
- ☞ 텍스트, 태그, 스크립트로 구성

```
<!DOCTYPE html>
<html>
<head>
<meta charset="utf-8">
<title>실습 7-2 </title>
<script language="JavaScript">
    function JSTest(a) {
        var age = a.value ;
        if( isNaN(age)== true){
            alert("숫자만 입력하세요");
            a.value = "";
        } else if ((age < 0) || (age>150)) {
            alert("0-150사이의 숫자를 입력하세요");
            a.value ="" ;
            a.focus() ;
        } else { alert("당신의 나이는"+age+"세 입니다");
        }
    }
</script> </head>
<body>
<form name="FRM" >
    나이 : <input name="age", type="text", size="5">
    <input type="button" value="전송"
onclick="JSTest(FRM.age)">
</form>
</body> </html>
```

1.4 데이터 샘플

1.10 데이터 샘플

2 반정형 Data: XML

- ☞ eXtensible Markup Language의 약자
- ☞ SGML 문서 형식을 가진 다른 특수한 목적을 갖는 마크업 언어를 만드는 데 사용하는 다목적 마크업 언어
- ☞ 데이터 표현을 위해 태그 사용
- ☞ 엘리먼트, 속성, 처리 명령, 엔티티, 주석, CDATA 섹션으로 구성

```
<?xml version="1.0" encoding="UTF-8"?>
```

```
<feature
```

```
  id="org.eclipse.help"
```

```
  label="%featureName"
```

```
  version="2.0.103.v20150204-1700"
```

```
  provider-name="%providerName"
```

```
  plugin="org.eclipse.help.base">
```

```
  <description>
```

```
    %description
```

```
  </description>
```

```
  <copyright>
```

```
    %copyright
```

```
  </copyright>
```

```
  <license url="%licenseURL">
```

```
    %license
```

```
  </license>
```

```
</feature>
```


1.4 데이터 샘플

1.10 데이터 샘플

3 반정형 Data: CSV

- ☞ Comma Separated Values의 약자
- ☞ 몇 가지 필드를 쉼표로 구분한 텍스트 데이터 및 텍스트 파일

노선번호,시간,승차,하차
 line_1,2223,576958,218944
 line_1,2324,260729,143872
 line_1,2401,21167,49352
 line_2,506,608841,140073
 line_2,607,1079186,947840
 line_2,708,2960789,2323675
 line_2,809,3914929,5683879

4 반정형 Data: JSON

- ☞ JavaScript Object Notation의 약자
- ☞ <키:값>으로 이루어진 데이터 오브젝트를 전달하기 위해 텍스트를 사용하는 개방형 표준 포맷

```
{
  "SET_CODE"      : "121959",
  "GOOD_GB"       : "아파트",
  "SET_NAME"      : "장성경성홈타운",
  "ZIPCD_BG"      : "791-759",
  "JS_BUNGI1"     : "경상북도 포항시 북구 장성동 1560-1",
  "JS_BUNGI2"     : "경상북도 포항시 북구 장성동",
  "ZIPCD_LD"      : "50062"
}
```

2. 빅데이터 처리방식

2.1 처리방식의 종류

2.2 배치처리

2.3 대화형처리

2.4 실시간처리

2. 빅데이터 처리방식

2.1 처리방식의 종류

배치 처리
(Batch
Processing)

대화형 처리
(Interactive
Processing)

실시간 처리
(Real-time
Processing)

2.2 배치처리

일일, 주간, 월간 보고서작성


주기적 작업을 일괄적으로 수행하는 형식

답변을 얻기까지 일정시간이 소요되는
처리 방식

2. 빅데이터 처리방식

2.2 배치처리



❶ 배치처리에 사용되는 프로그램



2. 빅데이터 처리방식

2.2 배치처리

2 배치 스케줄링 및 실행환경



2.3 대화형 처리

원하는 질의에 대해 수초 내에 답을 얻는
형태



2. 빅데이터 처리방식


2.3 대화형 처리

❶ 대화형 처리에 사용되는 프로그램

하이프
(Hive)

피그
(Pig)

스파크
(Spark)



```
Hadoop Command Line - hive
OK
hivesampletable
Time taken: 1.582 seconds, Fetched: 1 row(s)
C:\apps\dist\hive-0.13.0.2.1.10.0-2290\bin>hive

Logging initialized using configuration in file:/C:/apps/dist/hive-0.13.0.2.1.10.0-2290/conf/hive-log4j.properties
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/C:/apps/dist/hadoop-2.4.0.2.1.10.0-2290/share/hadoop/common/lib/slf4j-log4j12-1.7.5.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/C:/apps/dist/hbase-0.98.0.2.1.10.0-2290-hadoop2/lib/slf4j-log4j12-1.6.4.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.slf4j.impl.Log4jLoggerFactory]
hive> select * from hivesampletable limit 3;
3      18:54:28      en-US      Android Samsung SCH-i500      California
United States  13.9204007      0      0
23     19:19:44      en-US      Android HTC      Incredible      Pennsylvania
United States  NULL      0      0
23     19:19:46      en-US      Android HTC      Incredible      Pennsylvania
United States  1.4757422      0      1
Time taken: 2.897 seconds, Fetched: 3 row(s)
hive> _
```

◀ 하이브(Hive)의 대화형 모드 ▶

2. 빅데이터 처리방식

```
File Edit View Terminal Help
[hue@sandbox ~]$ pig -x local -4 log4j.prop
grunt> records = LOAD 'sample.tdf' AS (year:chararray, temp:int, qual:int);
grunt> DUMP records;
(1950,0,1)
(1950,22,1)
(1950,-11,1)
(1949,111,1)
(1949,78,1)
grunt> ILLUSTRATE records;
(1949,78,1)
-----
| records      | year:chararray | temp:int  | qual:int  |
-----
|              | 1949           | 78        | 1         |
-----
grunt> 
```

피그(Pig)의 대화형 모드

[illegible]

스파크(Spark)의 대화형 모드

2. 빅데이터 처리방식

2.4 실시간 처리

1

수 초 미만 또는 1초 미만의 실시간 처리 및 이벤트성 응답

2

데이터 스트림 처리

3

데이터가 수집되는 즉시, 실시간 전처리, 실시간 계산, 실시간 패턴 분석을 처리

4

결제나 비정상 카드 사용 등에 대한 데이터 분석에 사용



1 실시간 처리에 사용되는 프로그램

스톰
(Storm)

스파크
스트리밍
(Spark
Streaming)

2. 빅데이터 처리방식

2.4 실시간 처리

■ 스톱(Strom)

실시간 분석

온라인 머신러닝

연속적인 계산

ETL 작업

■ 스파크(Spark Streaming)

높은 대용량 데이터 처리

▶ 데이터는 카프카(Kafka), 플럼(Flume), 케네시스(Kinesis), TCP 소켓 등을 통해 수집

실시간 스트림 처리

맵리듀스, 조인, 윈도우 등과 같은 복잡한 알고리즘 사용 가능

출력으로 파일시스템, 데이터베이스, 실시간 대쉬보드 등을 지원

3. 빅데이터 처리를 위한 분산처리시스템

3.1 File System

3.2 Storage System

3.3 하둡 소개

3.4 하둡 구성

3.5 하둡 분산 파일시스템


3.6 하둡 분산 처리시스템

3.5 고가용성(HA) HDFS

3.1 File System

파일시스템 개요

- 컴퓨터에서 파일이나 자료를 쉽게 발견 및 접근할 수 있도록 보관 또는 조직하는 체제를 가리키는 말이다.
- 파일 하나를 디스크 공간에 저장하기 위한 최소공간을 클러스터 또는 블록이라 한다.
- 크기가 일정한 블록의 배열(섹터)에 접근할 수 있는 파일의 정보를 표시한다.




<그림 3. EXT2 파일 시스템의 물리적 배치도>

3.1 File System

파일시스템 종류

- ① FAT16(File Allocation Table)
FAT32, exFAT(FAT64)
- ② NTFS(New Technology File System : Windows NT
File System)
- ③ EXT(extended file system, 확장 파일 시스템)
EXT2, EXT3, EXT4
- ④ UFS(Unix File System)
- ⑤ NFS(Hierarchical File System, HFS: Mac OS)
- ⑥ APFS(Apple file system, APFS: apple macOS, iOS
watchOS, tvOS)



3.2 Storage System

■ 스토리지 시스템 (Storage System)

1. 정의

- 단일 디스크로 처리할 수 없는 용량을 저장하기 위해 디스크를 묶어서 논리적으로 사용하는 기술
- 스토리지 구성은 서버와 저장장치를 연결하는 방법이다.

2. 스토리지 시스템의 필요성

- 데이터의 양적 팽창이 급증함에 따른 데이터의 효율적인 저장 및 관리 필요
- 기업의 정보(Information) 자원을 이용한 새로운 비즈니스의 창출
- ERP, DW, Data Mining 등의 Application 등장

3. 스토리지 시스템의 요구조건

- 통합 관리를 통한 대용량, 고속 데이터 처리
- 효율적인 데이터 공유 (공유, 분배, 보안 강화)
- 확장성, 유연성, 서버 접속의 용이성


4. 스토리지 시스템의 유형별 특징

- 전통적인 Storage 접속 방법 : DAS(Direct Attached Storage)
- 네트워크 Storage 접속 방법 :
 - SAN(Storage Area Network)
 - NAS(Network Attached Storage)

3.2 Storage System

■ DAS(Direct Attached Storage)


- 서버가 채널(SCSI 또는 Fiber Channel)을 통해 저장 장치에 직접 연결하여 사용하는 방식.
- 서버에 직접 외장 저장 장치를 추가하므로 속도는 빠르고 확장은 쉽지만, 연결 수에 한계가 있다.
- 각 서버는 자신이 직접 파일 시스템을 관리한다.



3.2 Storage System

■ NAS(Network Attached Storage)


- 서버와 저장 장치가 이더넷 등의 LAN 방식의 네트워크에 연결된 방식이다.
- LAN 은 TCP/IP 프로토콜 기반이고 저장장치는 SCSI를 사용하므로 이들 간의 통신을 위해 중계 역할을 하는 파일 서버가 필요하다.
- 이 기종 클라이언트들에 데이터 액세스를 제공하는 컴퓨터 네트워크에 연결된 파일 수준 컴퓨터 데이터 저장 서버이다.



3.2 Storage System

■ SAN(Storage Area Network)

- 서버와 저장 장치를 Fiber Channel Switch로 연결한 고속 데이터 네트워크.
- 저장 장치를 향상시켜 장치가 로컬 연결 장치로 서버의 운영 체제에 표시되게 한다.
- SAN 구성에 확장성, 유연성, 가용성이 우수함



3.2 Storage System

■ 스토리지 시스템 비교


구분	DAS	NAS	SAN
구성요소	어플리케이션 서버, 스토리지	어플리케이션 서버, 전용 파일 서버, 스토리지	어플리케이션 서버, 스토리지
접속장치	없음	이더넷 스위치	파이버채널 스위치
스토리지 공유	가능	가능	가능
파일시스템 공유	불가능	가능	불가능
파일시스템 관리	어플리케이션 서버	파일 서버	어플리케이션 서버
접속 속도 결정요인	채널속도	LAN과 채널속도	채널속도
특징	소규모 독립된 구성에 적합	파일 공유를 위한 가장 안정적이고 신뢰성 높은 솔루션	유연성/확장성/편의성이 가장 뛰어남

3.3 하둡 소개

■ Apache 재단



Apache Hadoop Ecosystem



하둡 에코 시스템 사례

3.3 하둡 소개


+ 하둡이란?

하둡(Hadoop)

- 단순한 프로그래밍 모델을 사용하는 컴퓨터 클러스터에서 대형 데이터 세트의 **분산형 처리를 가능하게 하는 프레임워크**
- 단일 서버에서 각각 로컬 연산 및 저장 기능을 제공하는 수천 대의 장비로 스케일업(Scale Up) 되도록 설계됨
- 하드웨어에 의존해 높은 가용성을 제공하는 대신, 라이브러리 자체가 애플리케이션 계층에서 고장을 감지하고 처리할 수 있도록 설계됨

+ 하둡의 특징


- 1 비용에 대한 부담이 없음
- 2 데이터의 복제본을 저장하기 때문에 데이터의 유실/장애 발생 시 **데이터 복구 가능**
- 3 분산 파일 시스템인 **HDFS(Hadoop Distributed File System)**에 데이터를 저장하고 분산 처리 프레임워크인 **맵리듀스(MapReduce)**를 이용한 데이터 처리



3.4 하둡의 구성


1 Hadoop Common

+ 하둡 프레임워크



+ 하둡의 서버구축


- 하둡 분산 파일 시스템과 하둡 맵리듀스는 **마스터-슬레이브 구조**를 가지고 있음
 - : 전체 하둡 구성을 위해서 하나의 마스터 노드와 여러 대의 슬레이브 노드를 이용해서 구축할 수 있음
- 하둡 실행 방법
 - 하둡 분산 파일 시스템 구성을 위한 네임 노드, 세컨더리 네임 노드 구동
 - 하둡 맵리듀스 구성을 위한 데이터 노드 구동
 - 잡 트래커와 태스크 트래커 구동



34 하둡의 구성

2 HDFS : Hadoop Distributed File System

- + 구글 파일 시스템(GFS) 논문을 따라 모델링 한 분산 파일 시스템
- + 일반적인 분산 파일 시스템과 같이 마스터 슬레이브 구조로 구성
 - 마스터 노드 = 네임 노드(name node)
 - 슬레이브 노드 = 데이터 노드(data node)
- + 네임 노드와 데이터 노드의 역할
 - 네임 노드(name node)
 - : 데이터 노드들을 관리하고 데이터 노드에 저장되어 있는 사용자 데이터의 메타데이터 관리
 - 데이터 노드(data node)
 - : 사용자의 데이터를 저장하고 사용자의 요청에 따라 데이터를 저장 및 복제하여 보관



34 하둡의 구성

3 Hadoop MapReduce

맵리듀스(MapReduce)


- 구글에서 대용량 데이터 처리를 분산 병렬 컴퓨팅에서 처리하기 위한 목적으로 제작하여 2004년 발표한 소프트웨어 프레임워크
- 페타바이트 이상의 대용량 데이터를 신뢰도가 낮은 컴퓨터로 구성된 클러스터 환경에서 병렬 처리를 지원하기 위해서 개발된 프레임워크
- 함수형 프로그래밍에서 일반적으로 사용되는 MAP와 REDUCE라는 함수 기반으로 주로 구성됩니다.
- 현재 맵리듀스는 자바와 C++, 기타 언어에서 적용이 가능하도록 작성됨
- 대표적으로 아파치 하둡에서 오픈 소스 소프트웨어로 적용됨

+ 마스터 노드와 슬레이브 노드의 역할을 잡 트래커와 태스크 트래커가 담당

- 마스터 노드 = 잡 트래커(Job Tracker)
- 슬레이브 노드 = 태스크 트래커(Task Tracker)

+ 잡 트래커와 태스크 트래커의 역할

- 잡 트래커(Job Tracker) : 맵리듀스가 수행할 전체 작업을 중앙에서 관리
- 태스크 트래커(Task Tracker) : 실제 맵리듀스 작업 수행



3.5 하둡 분산 파일시스템

1 시스템 전체 구성


+ 일반적인 분산 파일 시스템의 구성

마스터 노드 (Master Node)

- 실제 데이터를 저장하는 서버
- 저장되어 있는 데이터를 관리하는 역할

슬레이브 노드 (Slave Node)

- 실제 데이터를 저장하는 역할
- 사용자 요청에 따라 데이터를 전달해 주는 역할



+ 마스터 노드(Master Node)

■ 분산 파일 시스템에서 마스터 노드의 역할

- 1 분산 파일 시스템의 모든 슬레이브 노드 관리
- 2 디렉토리와 파일에 대한 정보를 포함하는 메타데이터(Metadata) 관리

참고

메타데이터(Metadata)

- 파일은 각 파일별로 파일을 위한 추가 정보들이 있음
- 파일 시스템에 저장한다면 파일 이름, 파일의 크기, 파일의 생성 시간 등 파일의 내용뿐만 아니라 필요한 추가 정보들까지 저장하고 있음
- ➡ 이러한 정보들을 메타데이터라고 함


3.5 하둡 분산 파일시스템

1 시스템 전체구성

파일을 기본적으로 64MB 혹은 128MB 블록 단위로 나누어
여러 개의 데이터 노드에 분산 저장함

복제본의 수는 시스템에서 설정할 수 있음(디폴트: 3)

파일의 메타정보는 마스터 노드의 네임 노드가 관리하고
실제 블록 데이터는 작업 노드인 데이터 노드에 분산 저장됨





하둡 분산 파일 시스템 예시

3.5 하둡 분산 파일시스템

2 시스템구성(Name Node)

+ 마스터 노드(Master Node)

■ 분산 파일 시스템에서 마스터 노드의 역할



3.5 하둡 분산 파일시스템

2 시스템구성(Name Node)

1

클라이언트로부터 특정 파일에 대한 요구 발생

2

해당 파일을 보관하고 있는 블록들에 대한 정보 탐색

3

실제 데이터가 보관되어 있는 데이터 노드에 대한 위치를 알려줌

4


실제 데이터 접근은 데이터 노드를 통해 이루어짐

3.5 하둡 분산 파일시스템

3 시스템구성(데이터노드)

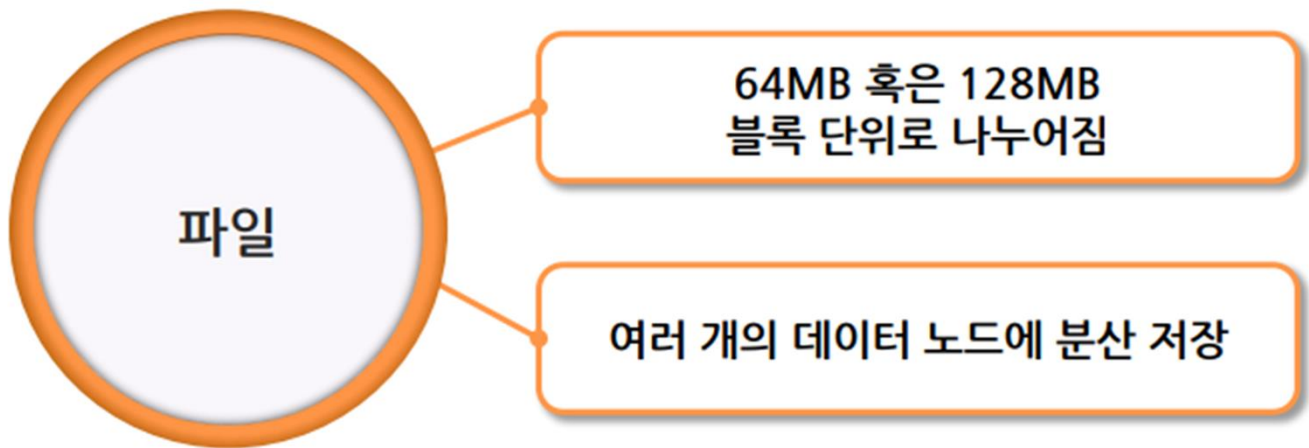
+ 슬레이브 노드(Slave Node)

- 사용자의 데이터를 저장하는 역할을 담당
- 사용자가 파일을 업로드 하거나 다운로드 할 때 사용자에게 데이터를 전달
- 분산 파일 시스템 환경에서 하나의 파일을 한 개 이상의 슬레이브 노드에 동일하게 복제하여 관리하는 역할 수행



3.5 하둡 분산 파일시스템

3 시스템구성(데이터노드)



블록들은 복제(Replication)를 통해 여러 개의 데이터 노드에 저장

신뢰성 보장

- 하나의 복제본이 손실되어도 아무런 결함 없이 사용될 수 있도록 함

데이터 지역성(Data Locality) 향상


- 실행을 위해 데이터 이동 없이 블록이 저장된 곳에서 수행할 수 있도록 함

3.5 하둡 분산 파일시스템

■ Hadoop 파일 쓰기/읽기

① 데이터 쓰기


HDFS에 파일을 저장하면

파일의 데이터를
슬라이스로 분할하둡 클러스터의 여러
노드에 이중으로 저장함➤ 대용량 파일을 작은
단위의 블록으로 나눔

3.5 하둡 분산 파일시스템

■ Hadoop 파일 쓰기/읽기


② 데이터 읽기



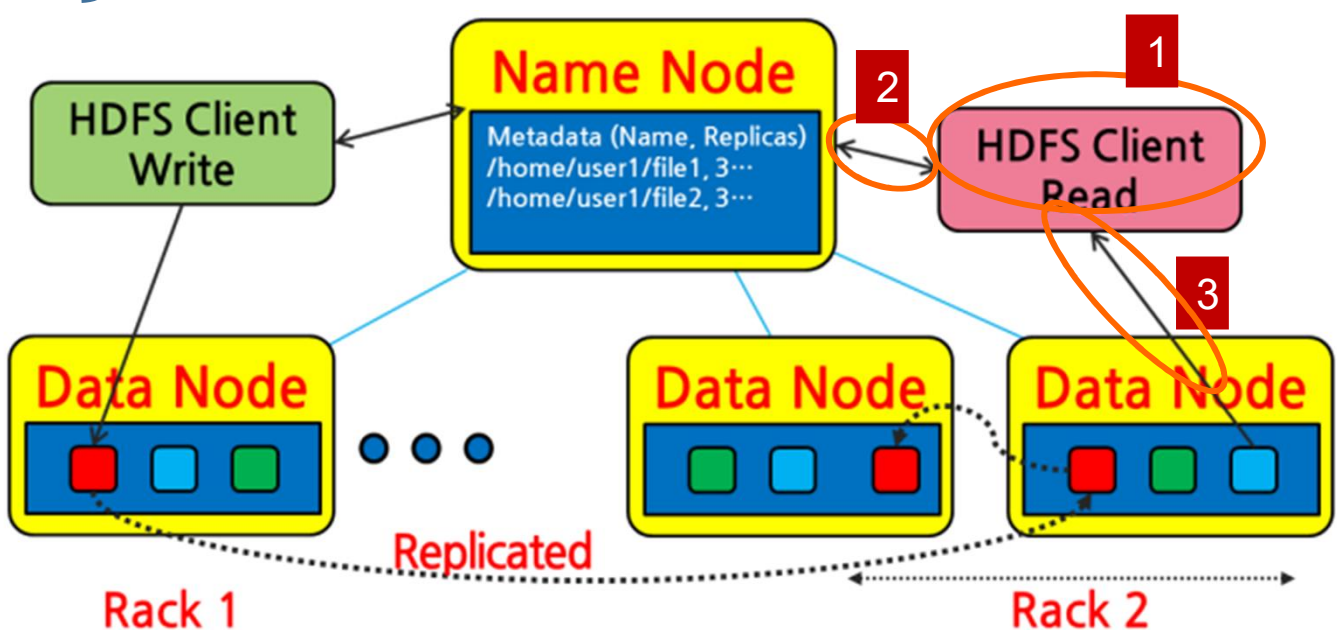
3.5 하둡 분산 파일시스템

Hadoop 파일 쓰기/읽기

3 전체 흐름



2 파일 읽기




3.6 하둡 분산 처리시스템

1 맵리듀스(Map Reduce)

맵리듀스 프레임

분산 병렬 처리 방식으로
여러 개의 작업 노드에
작업을 분산하여 병렬
수행할 수 있는
프레임워크를 제공



맵리듀스(MapReduce)

맵(Map) + 리듀스(Reduce)


3.6 하둡 분산 처리시스템

2 맵리듀스 프레임워크

● 처리과정




● 데이터 흐름



3.6 하둡 분산 처리시스템

3 맵리듀스 처리방법




시스템(하둡: Hadoop)이 자동으로 처리함

3.6 하둡 분산 처리시스템

3 맵리듀스 처리방법

1 하둡이 MAP()함수에 데이터 할당




2 MAP()함수 <key, value>출력



3.6 하둡 분산 처리시스템

3 맵리듀스 처리방법


3 하둡이 <key, value>데이터를 그룹핑




3.6 하둡 분산 처리시스템

3 맵리듀스 처리방법

4 하둡이 그룹핑 데이터 reduce() 에 할당




5 reduce()는 <key, value> 결과를 출력



3.6 하둡 분산 처리시스템

3 맵리듀스 처리방법

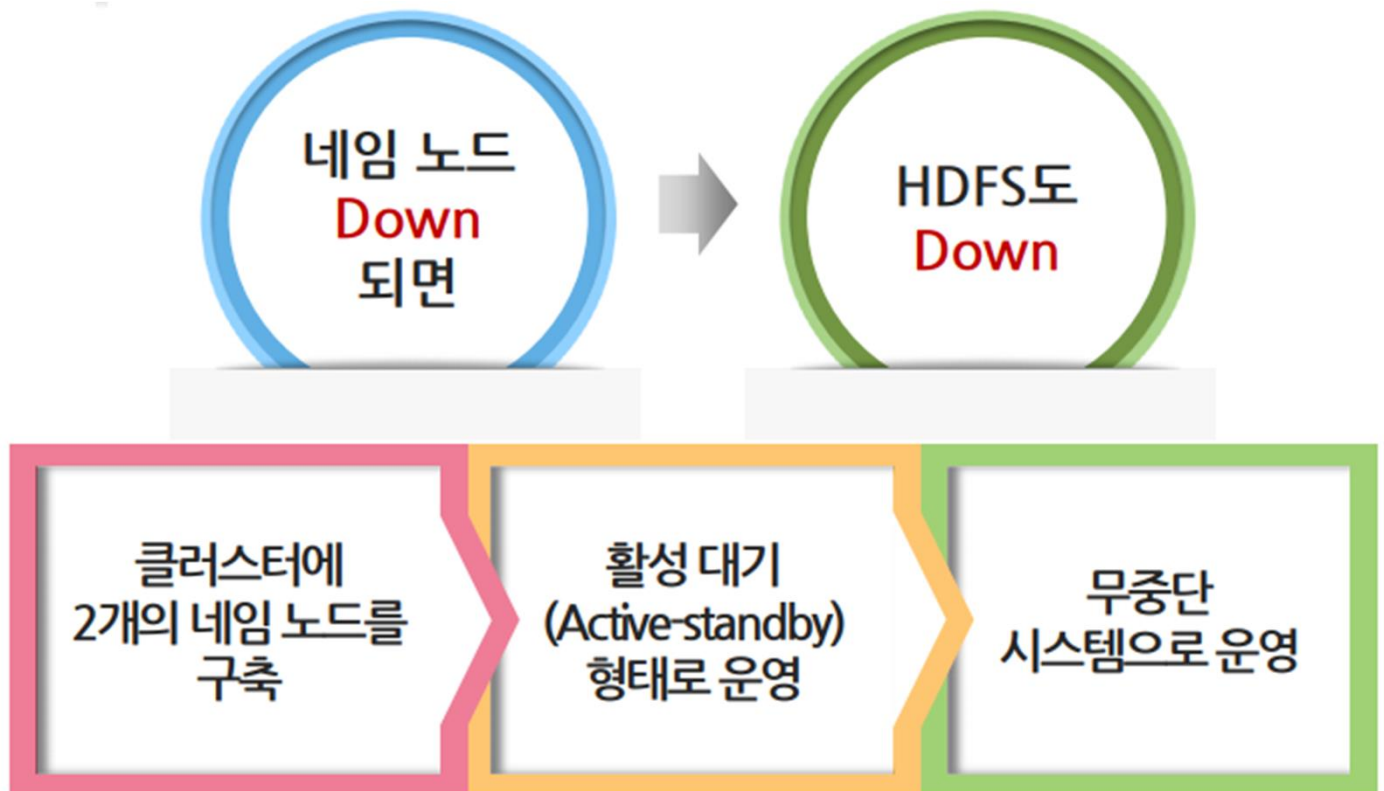
4 하둡이 그룹핑 데이터 reduce() 에 할당



Word Count 문제 예시

3.7 고 가용성 HDFS

1 단일구성 Name Node





해당 파일들의 메타정보를 보관하는 역할을 수행

실제 파일 내용은 보관하지 않음

3.7 고 가용성 HDFS

2 이중구성 Name Node



별도의 보조 네임 노드가 필요 없음

체크포인트는 대기 네임 노드가 수행


3.7 고 가용성 HDFS

3 Standby Name Node

1 활성 네임 노드와 항상 동일한 정보 상태를 유지함

2 데이터 노드로부터 같이 정보를 받음

➤ 활성 네임 노드에 장애 발생 시,
자동으로 활성 네임 노드로 전환



◀ 활성/대기 네임 노드 구성 ▶

4. 빅데이터 하둡에코 솔루션

4.1 클라우데라


4.2 호튼웍스

4. 빅데이터 솔루션

1. 클라우데라(Cloudera)




1. 클라우데라 하둡(CDH)에코 시스템




4. 빅데이터 솔루션

2. 호튼웍스(Hortonworks)



1 호튼웍스(HDP)하둡 에코 시스템



5. 빅데이터 클라우드 컴퓨팅

5.1 MS Azure

5.2 아마존 AWS

5.3 구글 GCP

4. 빅데이터 클라우드 컴퓨팅

1. 마이크로소프트 애저(Azure)

<https://azure.microsoft.com/ko-kr/>

The screenshot shows the Microsoft Azure website interface. At the top, there's a navigation bar with the Microsoft Azure logo, a link to '영업팀에 문의' (Contact Sales), a search icon, and links for '내 계정' (My Account), '포털' (Portal), and '로그인' (Login). Below this is a secondary navigation bar with links for '개요' (Overview), '솔루션' (Solutions), '제품' (Products), '설명서' (Documentation), '가격' (Pricing), '교육' (Education), 'Marketplace', '파트너' (Partners), '지원' (Support), '블로그' (Blog), and '기타' (Other). A '체험 계정 >' (Free Account) link is also present.

The main content area is divided into several sections. On the left, there's a '추천' (Recommended) section with a list of categories: AI + 머신 러닝, 분석기능, 블록체인, 컴퓨팅, 컨테이너, 데이터베이스, DevOps, 개발자 도구, Hybrid + Multicloud, ID, and 통합. Each category has a corresponding sub-category listed next to it. For example, 'AI + 머신 러닝' is linked to '관리 및 거버넌스', '분석기능' to '미디어', '블록체인' to '마이그레이션', '컴퓨팅' to '혼합 현실', '컨테이너' to '모바일', '데이터베이스' to '네트워킹', 'DevOps' to '보안', '개발자 도구' to 'Storage', 'Hybrid + Multicloud' to 'Web', 'ID' to 'Windows Virtual Desktop', and '통합' to 'Windows Virtual Desktop'.

Below the '추천' section is a search bar with the text '모든 제품 검색' (Search all products) and a link to '모두 보기 (200+개)' (View all (200+)).

The right side of the page features a '추천' (Recommended) section with a list of services: Azure 인기 제품 살펴보기 (Explore popular Azure products), 가상 머신 (Virtual Machines), Windows Virtual Desktop, Azure SQL, App Service, Azure Cosmos DB, PlayFab, Azure Kubernetes Service(AKS), Azure Function, Azure Cognitive Services, and Azure Quantum. Each service has a brief description of its capabilities.

4. 빅데이터 클라우드 컴퓨팅

1. 마이크로소프트 애저(Azure)

통합된 클라우드 가상머신 서비스 플랫폼


분석, 컴퓨팅, 데이터베이스, 모바일, 저장소, 웹 등 IT 인프라 서비스 제공

빅데이터 처리를 위한 하둡 매퍼듀스 프레임워크를 클라우드 서비스 형태로 제공

<https://azure.microsoft.com/ko-kr/>

개요 솔루션 제품 ▼ 설명서 가격 ▼ 교육 Marketplace 파트너 ▼ 지원 ▼ 블로그 기타 ▼


솔루션 전체 ▼ 제품 전체 ▼ 태그 전체 ▼ 산업 전체 ▼



의료 데이터 스토리지

Microsoft의 클라우드 및 하이브리드 솔루션을 사용하면 인텔리전스를 통합하고 준수를 유지하는 동시에 효율적이고 비...


[자세한 정보 >](#)



원격 분석

Cortana Intelligence 자동차 원격 분석 솔루션 템플릿을 소개합니다. 이 솔루션은 자동차 대리점, 자동차 제조업체 및 보...

[자세한 정보 >](#)



하이브리드 SharePoint 팜 및 Office 365

SharePoint를 배포하고 Office 365와 하이브리드 워크로드를 공유하여 고가용성 인트라넷 기능을 배포합니다. 단계별 지...

[자세한 정보 >](#)



최신 데이터 웨어하우스



개발 테스트용 SharePoint 팜




클라우드에서 배포된 HPC 클러스터

4. 빅데이터 클라우드 컴퓨팅

1. 마이크로소프트 애저(Azure)

1. 원격 분석 솔루션(사례)

Cortana Intelligence 자동차 원격 분석 솔루션 템플릿입니다.
이 솔루션은 자동차 대리점, 자동차 제조업체 및 보험 회사가 Cortana Intelligence 기능을 사용하여 자동차 상태와 운전 습관에 대한 실시간 및 예측 정보를 얻는 방법을 보여 줍니다.



6. Azure 하둡서버 구축하기

- ① 아마존 AWS 혹은 MS의 Azure와 같은 클라우드 컴퓨팅 환경의 이용을 위해 관련 사이트에서 계정 생성

- ✓ MS Azure 포털 사이트 주소

portal.azure.com

Microsoft Azure

Microsoft

계정 만들기

Microsoft 계정을 사용하면 다양한 혜택을 누릴 수 있습니다.

someone@example.com

암호 만들기

☐ Microsoft에서 보내는 홍보용 전자 메일 수신

동의하고 계정 만들기

취소

전화 번호를 대신 사용

새 전자 메일 주소 받기

동의를 하고 계정 만들기를 선택하면 Microsoft 서비스 계약 및 개인정보처리방침에도 동의하는 것이며, 여기에는 수집된 계정 데이터, 개인 데이터 사용 및 보존 기간이 포함됩니다.

계정 생성 화면 예시 1

4. 빅데이터 클라우드 컴퓨팅

2. 아마존 AWS(Amazon Web Services)

Amazon Web Services(AWS)는 전 세계적으로 분포한 데이터 센터에서 175개가 넘는 완벽한 기능의 서비스를 제공하는, 클라우드 플랫폼입니다.

<https://aws.amazon.com/ko-kr/>

The screenshot shows the AWS Korean homepage. At the top, there's a navigation bar with the AWS logo, links for '문의하기' (Contact Us), 'Support', '고객지원' (Customer Support), '한국어' (Korean), and '내 계정' (My Account). An orange button for 'AWS 계정 생성' (Create AWS Account) is on the right. Below the navigation bar is a secondary bar with links for '제품' (Products), '솔루션' (Solutions), '요금' (Pricing), '설명서' (Documentation), '학습하기' (Learn), '파트너 네트워크' (Partner Network), 'AWS Marketplace', '고객 지원' (Customer Support), and '더 알아보기' (Learn More). The main content area is divided into three columns. The left column lists '주요 서비스' (Key Services) with links to '분석' (Analytics), '애플리케이션 통합' (Application Integration), 'AWS 비용 관리' (AWS Cost Management), '블록체인' (Blockchain), '비즈니스 애플리케이션' (Business Applications), '컴퓨팅' (Computing), '컨테이너' (Containers), '고객 참여' (Customer Engagement), '데이터베이스' (Database), '개발자 도구' (Developer Tools), '최종 사용자 컴퓨팅' (End User Computing), '프런트 엔드 웹 및 모바일' (Frontend Web and Mobile), 'Game Tech', and '사물 인터넷' (IoT). The middle column lists '주요 서비스' (Key Services) with links to 'Amazon EC2' (Cloud's virtual server), 'Amazon Simple Storage Service(S3)' (Cloud storage), 'Amazon Aurora' (Managed database), 'Amazon DynamoDB' (Managed NoSQL database), 'Amazon RDS' (Managed relational database), and 'AWS Lambda' (Serverless). The right column lists '리소스 및 미디어' (Resources and Media) with links to '블로그' (Blog), '최신 AWS 블로그 읽기' (Read the latest AWS blog), 'AWS 새로운 소식' (AWS news), 'AWS 서비스에 대한 공지 확인' (Check for announcements about AWS services), '고객 지원' (Customer Support), 'AWS IQ' (AWS IQ), 'AWS 공인 타사 전문가의 도움을 받아 더 신속하게 프로젝트 완료하기' (Get help from AWS certified third-party experts to complete your project faster), 'AWS Managed Services' (AWS Managed Services), and 'AWS 인프라 운영 위임하기' (Delegate AWS infrastructure operations).

aws

문의하기 Support 고객지원 한국어 내 계정 AWS 계정 생성

제품 솔루션 요금 설명서 학습하기 파트너 네트워크 AWS Marketplace 고객 지원 더 알아보기 Q

주요 서비스

분석

애플리케이션 통합

AWS 비용 관리

블록체인

비즈니스 애플리케이션

컴퓨팅

컨테이너

고객 참여

데이터베이스

개발자 도구

최종 사용자 컴퓨팅

프런트 엔드 웹 및 모바일

Game Tech

사물 인터넷

주요 서비스

Amazon EC2
클라우드의 가상 서버

Amazon Simple Storage Service(S3)
클라우드에서의 확장 가능한 스토리지

Amazon Aurora
관리형의 고성능 관계형 데이터베이스

Amazon DynamoDB
관리형 NoSQL 데이터베이스

Amazon RDS
MySQL, PostgreSQL, Oracle, SQL Server 및 MariaDB를 위한 관리형의 관계형 데이터베이스 서비스

AWS Lambda
서버에 대한 걱정 없이 코드 실행

리소스 및 미디어

블로그

최신 AWS 블로그 읽기

AWS 새로운 소식

AWS 서비스에 대한 공지 확인

고객 지원

AWS IQ

AWS 공인 타사 전문가의 도움을 받아 더 신속하게 프로젝트 완료하기

AWS Managed Services

AWS 인프라 운영 위임하기

4. 빅데이터 클라우드 컴퓨팅

3. 구글 GCP(Google Cloud Platform)

사전 패키징된 SAP, VMware, Windows, Oracle, 데이터 센터 마이그레이션, 기타 기업 워크로드용 클라우드 인프라 솔루션 제공

데이터 웨어하우스, 분석, AI, 머신러닝을 위한 확장형 솔루션 모음으로 데이터에서 활용 가능한 분석 정보제공

애플리케이션을 한 번만 빌드하여 다른 클라우드 제공업체의 하이브리드 및 멀티 클라우드 환경에서 실행가능

<https://cloud.google.com/>

The screenshot displays the Google Cloud Platform (GCP) homepage. At the top, there's a navigation bar with the Google Cloud logo, a search bar, and links for 'Google을 선택해야 하는 이유' (Why choose Google?), '솔루션' (Solutions), '제품' (Products), '가격 책정' (Pricing), '시작하기' (Get started), and '문의하기' (Contact us). There's also a 'Language' dropdown and a '콘솔' (Console) link.

On the left, a sidebar menu lists various categories: '추천 제품' (Recommended products), 'AI 및 머신러닝' (AI and Machine Learning), 'API 관리' (API Management), '컴퓨팅' (Computing), '컨테이너' (Containers), '데이터 분석' (Data Analytics), '데이터베이스' (Databases), '개발자 도구' (Developer Tools), '의료 및 생명과학' (Health and Life Sciences), '하이브리드 및 멀티 클라우드' (Hybrid and Multi-Cloud), and '사물 인터넷' (IoT). A button at the bottom of the sidebar says '모든 제품 보기(100개 이상)' (View all products (100+)).

The main content area is titled '추천 제품' (Recommended products) and features a grid of product cards:

- Compute Engine**: Google의 데이터 센터에서 실행되는 가상 머신 (Virtual machines running in Google's data centers).
- Cloud Storage**: 안전하고 내구성과 확장성이 뛰어난 객체 스토리지 (Secure and durable, scalable object storage).
- Cloud SDK**: Google Cloud용 명령줄 도구 및 라이브러리 (Command-line tools and libraries for Google Cloud).
- Cloud SQL**: MySQL, PostgreSQL, SQL Server용 관계형 데이터베이스 서비스 (Relational database service for MySQL, PostgreSQL, SQL Server).
- Google Kubernetes Engine**: 컨테이너식 앱 실행을 위한 관리형 환경 (Managed environment for containerized app execution).
- BigQuery**: 비즈니스 민첩성을 높이고 유용한 정보를 얻기 위한 데이터 웨어하우스 (Data warehouse to increase business agility and gain useful insights).
- Cloud CDN**: 웹 및 동영상 전송을 위한 콘텐츠 전송 네트워크 (Content delivery network for web and video delivery).
- Dataflow**: 스트림 및 일괄 처리를 위한 스트리밍 분석 (Streaming analytics for stream and batch processing).
- 운영**: 모니터링, 로깅, 애플리케이션 성능 측정 (Monitoring, logging, application performance measurement).
- Cloud Run**: 컨테이너식 앱 실행을 위한 완전 관리형 환경 (Fully managed environment for containerized app execution).
- Cloud Functions**: 클라우드 서비스 및 앱을 위한 이벤트 기반 컴퓨팅 플랫폼 (Event-driven computing platform for cloud services and apps).

At the bottom right, there's a link '원하는 내용을 찾을 수 없으신가요?' (Can't find what you're looking for?) and a button '모든 제품 보기(100개 이상)' (View all products (100+)).

6. 빅데이터 실습


6.1 WordCount

6.2 Azure 하둡구축

6.3 클라우데라 하둡에코 구축

7. Word Count 실습

1 워드카운트 개요



7. Word Count 실습

2 WordCount실습 순서





✓ 결과 확인




7. Word Count 실습

3 Maven project 생성



7. Word Count 실습

3 Maven project 생성



The image shows the 'New Maven Project' dialog box in an IDE. The title bar says 'New Maven Project'. Below the title bar, it says 'New Maven project' and 'Specify Archetype parameters'. There is a Maven logo icon on the right. The dialog contains several input fields: 'Group Id' with the value 'bigdata', 'Artifact Id' with the value 'mapreduce', 'Version' with the value '0.0.1-SNAPSHOT', and 'Package' with the value 'bigdata.mapreduce'. Below these fields is a section titled 'Properties available from archetype:' which contains a table with two columns: 'Name' and 'Value'. To the right of the table are two buttons: 'Add...' and 'Remove'. At the bottom of the dialog, there is a section labeled 'Advanced' with a right-pointing arrow. At the very bottom, there are four buttons: a help icon (question mark), '< Back', 'Next >', and 'Finish' (which is highlighted with a blue border), and 'Cancel'.

New Maven Project

New Maven project
Specify Archetype parameters

Group Id: bigdata

Artifact Id: mapreduce

Version: 0.0.1-SNAPSHOT

Package: bigdata.mapreduce

Properties available from archetype:

Name	Value
------	-------

Advanced

< Back Next > Finish Cancel

3 Maven: pom.xml-hadoop

```
<dependency>
  <groupId>org.apache.hadoop</groupId>
  <artifactId>hadoop-mapreduce-examples</artifactId>
  <version>2.7.3</version>
  <scope>provided</scope>
</dependency>
<dependency>
  <groupId>org.apache.hadoop</groupId>
  <artifactId>hadoop-mapreduce-client-
common</artifactId>
  <version>2.7.3</version>
  <scope>provided</scope>
</dependency>
<dependency>
  <groupId>org.apache.hadoop</groupId>
  <artifactId>hadoop-common</artifactId>
  <version>2.7.3</version>
  <scope>provided</scope>
</dependency>
```

3 Maven: pom.xml-java

```
<dependency>
  <groupId>jdk.tools</groupId>
  <artifactId>jdk.tools</artifactId>
  <version>1.8</version>
  <scope>system</scope>
  <systemPath>D:/Program
    Files/Java/jdk1.8.0_211/lib/tools.jar</systemPath
  >
</dependency>
```


7. Word Count 실습

3 Maven: pom.xml-build

```
<build>
  <defaultGoal>install</defaultGoal>
  <plugins>
    <plugin>
      <groupId>org.apache.maven.plugins</groupId>
      <artifactId>maven-shade-plugin</artifactId>
      <version>2.3</version>
      <configuration>
        <transformers>
          <transformer
implementation="org.apache.maven.plugins.shade.resource.ApacheLicenseResourceTransformer">
            </transformer>
          </transformers>
        </configuration>
        <executions>
          <execution>
            <phase>package</phase>
            <goals>
              <goal>shade</goal>
            </goals>
          </execution>
        </executions>
      </plugin>
    <plugin>
      <groupId>org.apache.maven.plugins</groupId>
      <artifactId>maven-compiler-plugin</artifactId>
      <version>3.6.1</version>
      <configuration>
        <source>1.8</source>
        <target>1.8</target>
      </configuration>
    </plugin>
  </plugins>
</build>
```

7. Word Count 실습

4 Java 클래스 작성



- ▶ 작업에 대한 설정 정보
- ▶ 클러스터에 작업 제출 역할

7. Word Count 실습

4 Java Class 작성

① wc.java

1 메인 함수를 가지는 드라이버 코드

2 클라이언트에서 수행

3 작업 수행에 대한 변수들을 구성

4 클러스터에 작업을 제출하는 역할

② wcmapper.java

1 map 매서드를 가지는 매퍼 코드

2 워드카운트 프로그램의 입력을 받음

3 각 단어(키)와 1(값)을 key, value 쌍으로 구성해 줌

7. Word Count 실습

4 Java Class 작성

③ wcreducer.java

- 1 reduce 매서드를 가지는 리듀서 코드
- 2 매퍼 프로그램에서 만들어진 각 단어와 키값들의 리스트를 받음
- 3 해당하는 단어에 있는 값들의 합계를 구함
- 4 해당 단어가 나타난 빈도를 구함
- 5 최종 결과를 HDFS에 저장함

7. Word Count 실습

4 Java Class 작성: import

```
import java.io.IOException; // IO 예외처리
import java.util.StringTokenizer; // 스트링 토큰 처리기

import org.apache.hadoop.conf.Configuration; // 하둡 구성 정보
import org.apache.hadoop.fs.Path; // 파일 시스템 경로
import org.apache.hadoop.io.IntWritable; // 정수형 쓰기 가능 데이터 삽입
import org.apache.hadoop.io.Text; // 텍스트 데이터 타입
import org.apache.hadoop.mapreduce.Job; // 맷리듀스 Job
import org.apache.hadoop.mapreduce.Mapper; // 맷리듀스 맷퍼
import org.apache.hadoop.mapreduce.Reducer; // 맷리듀스 리듀서
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat; // 파일 입력 포맷
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat; // 파일 출력 포맷
```

4 Java Class 작성: TokenizerMapper

```
public class WordCount {
    public static class TokenizerMapper extends Mapper<Object, Text, Text, IntWritable> {
        Private final static IntWritable one = new IntWritable(1); // one 변수 선언
        Private Text word = new Text(); // word 변수 선언
        Public void map(Object key, Text value, Context context)
            throws IOException, InterruptedException {
            StringTokenizer itr = new StringTokenizer(value.toString());
            while (itr.hasMoreTokens()) {
                word.set(itr.nextToken()); // 단어를 하나씩 추출
                context.write(word, one); // (word, 1)의 쌍으로 출력
            }
        }
    }
}
```

7. Word Count 코딩하기

4 Java Class 작성: IntSumReducer

```
public static class IntSumReducer
    extends ReducerM<Text, IntWritable, Text, IntWritable> {
    Private IntWritable result = new IntWritable( ); // 결과를 담을 result 변수 선언

    Public void reduce(Text key, Iterable<IntWritable> value, Context context)
        throws IOException, InterruptedException {
        int sum = 0;
        for (IntWritable val : values) {
            sum += val.get( ); // value 의 값을 얻어서 합계
        }
        result.set(sum);
        context.write(key, result); // (key, result)의 쌍으로 출력
    }
}
```

4 Java Class 작성: Main

```
public static void main(String[ ] args) throws Exception {
    Configuration conf = new Configuration( ); // conf 객체 생성
    Job job = Job.getInstance(conf, "word count"); // "word count"라는 job 인스턴스 생성
    job.setJarByClass(WordCount.class);
    job.setMapperClass(TokenizerMapper.class);
    job.setCombinerClass(IntSumReducer.class);
    job.setReducerClass(IntSumReducer.class);
    job.setOutputKeyClass(Text.class);
    job.setOutputValueClass(IntWritable.class);
    FileInputFormat.addInputPath(job, new Path(args[0])); // 입력 파일 지정
    FileOutputFormat.setOutputPath(job, new Path(args[1])); // 목적지 파일 지정
    System.exit(job.waitForCompletion(true) ? 0 : 1); // 맵리듀스 job 제출
}
} // WordCount 클래스의 끝
```


7. Word Count 실습

5 컴파일 및 실행

① 컴파일과 실행

작성된 프로그램을 컴파일

자바 파일들을 JAR 파일로 만들

생성된 JAR 파일을 사용해서 하둡에 맵리듀스 프로그램을 제출

입력 파일에 있는 각 단어의 빈도를 카운트

출력 디렉토리에 결과를 저장

② 컴파일과 실행


```
$ javac *.java  
$ jar -cvf wordcount.jar *.class
```

③ 실행

```
$ hadoop jar wordcount.jar WordCount input-file output
```

7. Word Count 실습

5 컴파일 및 실행



```
cd /home/bigdata
```

```
hdfs dfs -mkdir /data
```

```
hdfs dfs -put *.txt /data/
```

```
yarn jar mapreduce-0.0.1-SNAPSHOT.jar
```

```
bigdata.mapreduce.WordCount /data/*.txt /wcnt
```

```
hdfs dfs -ls /
```

```
hdfs dfs -cat /wcnt/part-r-00000
```

```
hdfs dfs -gat /wcnt/part-r-00000
```

7. Word Count 실습


5 컴파일 및 실행

yarn jar 매개변수1 매개변수 2 매개변수 3 매개변수 4

```
yarn jar mapreduce-0.0.1-SNAPSHOT.jar  
bigdata.mapreduce.WordCount /data/*.txt /wcnt
```

- 1) yarn jar - jar파일 실행명령어
- 2) mapreduce-0.0.1-SNAPSHOT.jar.jar
- 컴파일한 jar파일
- 3) bigdata.mapreduce.WordCount
- jar내에 WordCount의 위치
- 4) /data/*.txt
- 하둡내에 분석하려는 파일
- 5) /wcnt
- 하둡에 분석결과를 보관하는 디렉토리


8. Raspberry Pi를 활용한 Hadoop 시스템 구축



라즈베리파이 4 B+ * 3

8. 빅데이터 에코시스템 실습

8.1 Hadoop시스템 H/W구성도



8. Raspberry Pi를 활용한 Hadoop 시스템 구축

windows 네트워크 설정

제어판 >>

네트워크 및 인터넷(네트워크 상태 및 작업보기) >>

어댑터 설정 변경 >>

Realtek USB FE Family Controll >>

인터넷 프로토콜 버전4(TCP/IPv4) >> 속성 >>

다음 IP주소 사용

인터넷 프로토콜 버전 4(TCP/IPv4) 속성

일반

네트워크가 IP 자동 설정 기능을 지원하면 IP 설정이 자동으로 할당되도록 할 수 있습니다. 지원하지 않으면, 네트워크 관리자에게 적절한 IP 설정값을 문의해야 합니다.

☐ 자동으로 IP 주소 받기(O)

☒ 다음 IP 주소 사용(S)

IP 주소(I): 192 . 168 . 50 . 10

서브넷 마스크(U): 255 . 255 . 255 . 0

기본 게이트웨이(D): 192 . 168 . 50 . 254

☐ 자동으로 DNS 서버 주소 받기(B)

☒ 다음 DNS 서버 주소 사용(E)

기본 설정 DNS 서버(P): . . .

보조 DNS 서버(A): . . .

☐ 끝낼 때 설정 유효성 검사(L)

고급(V)...

확인 취소

8. 2 Hadoop시스템 H/W구성도


master	worker01	worker02
- Hadoop management Nodes - Hadoop Name Nodes - HBase management - HBase Region Server	- Hadoop Data Nodes - HBase Region - 플럼 - 스파크	- Hadoop Data Nodes - HBase Region - Mysql - Apache WebServer
Raspberry Pi1 - Master.hadoop.com 192.168.50.101 - Raspberry Pi 5.10 - 자바 1.8환경	Raspberry Pi2 - Worker01.hadoop.com 192.168.50.102 - Raspberry Pi 5.10 - 자바 1.8환경	Raspberry Pi3 - Worker02.hadoop.com 192.168.50.103 - Raspberry Pi 5.10 - 자바 1.8환경

Window 10

X86 데스크탑 PC
(CPU:i7, RAM:16Gb, SSD:250Gb, HDD: 500Gb)

8. 빅데이터 에코시스템 실습

8. 1 Hadoop시스템 S/W구성도



8.3 NetWork 환경설정

1. sd card 설치 RaspberryPi OS 쓰기
raspberry 4B 64bit
2. dhcp server 운영
3. pi Telnet 접속
 - 1) hadoop 계정 생성
sudo addgroup hadoop
sudo adduser --ingroup hadoop namenode
sudo adduser namenode sudo
4. hadoop 계정 접속
 - 1) .bashrc 수정
vi ~/.bashrc
 - 2) /etc/Hostname 설정
- master, worker01, worker02
 - 3) /etc/Hosts 설정
192.168.56.101 master
192.168.56.102 worker01
192.168.56.103 worker02
 - 4) .ssh 인증키 설정
ssh-keygen -t ed25519

8.3 NetWork 환경설정

5. hadoop 설치

1) 하둡압축파일 Upload 및 down

2) 하둡압축해제

```
sudo tar -xvf hadoop-3.3.1.tar.gz -C /opt/  
rm hadoop-3.3.1.tar.gz && cd /opt  
sudo mv hadoop-3.3.1 hadoop
```

```
sudo chown hadoop:hadoop -R /opt/hadoop
```

3) 하둡 환경설정 및 관련 XML 수정

6. hadoop 운영 및 Echo 시스템 설치

1)하둡 구동

```
hdfs namenode -format
```

```
start-dfs.sh && start-yarn.sh
```

jps (Java Virtual Machine Process Status)

2)실행 확인

```
yarn node -list
```

```
hadoop dfsadmin -report
```

```
hdfs --daemon start datanode
```

```
hdfs --daemon start journalnode
```

```
hadoop-daemons.sh start datanode
```

```
nameNode.local:9870
```

8.3 NetWork 환경설정

7.Hadoop 기본명령어 실습

1)Sample File UpLoad

```
hdfs dfs -put Sample.txt /tmp
```

```
hdfs dfs -ls /tmp
```

```
hdfs dfs -cat /tmp/Sample.txt
```

```
hdfs dfs -cp /tmp/Sample.txt /tmp/Sample2.txt
```

2)HDFS의 파일시스템 통계 기본정보확인

```
hdfs dfsadmin -report
```

3)HDFS에 저장된 파일을 로컬 파일시스템으로 가져오기

```
hdfs dfs -get /tmp/Sample2.txt
```

4)HDFS에 저장된 파일 삭제

```
hdfs dfs -rm /tmp/Sample.txt
```

```
hdfs dfs -rm -rf /tmp
```

8.WordCount 실습및 실행

9. Echo 시스템 설치 및 운영

1) Flum

2) Mysql

3) Spark

참고자료

실무로 배우는 빅데이터기술 - 김강원저

<https://e-koreatech.step.or.kr> – 빅데이터 수집

<https://e-koreatech.step.or.kr> – 빅데이터 처리

https://choosunsick.github.io/post/hadoop_install/